

BOKMÅL

NHH



# SKOLEEKSAMEN MET4

Vår 2026

**Dato:** 23. april 2026

**Tidsrom:** 09:00 - 15:00

**Antall timer:** 6

**Foreleser/kursansvarlig kan kontaktes av eksamensvakt på telefon: 99385583**

TILLATTE HJELPEMIDLER:

Kalkulator      Ja ☒      Nei ☐

Ordbok: én tospråklig ordbok (kategori 1)

**Antall sider, inkludert forside: 8**

**Antall digitale vedlegg: 3** (sykler.Rdata, MET4-formelark.pdf, relevante\_r\_kommandoer.pdf)

**Antall fysiske vedlegg: 1** (MET4 Formelark)

## Del 1 - Dataanalyse med R

Bergen Bysykkel (`bergenbysykkel.no`) er et selskap som tilbyr sykkelutleie i Bergen. Selskapet ønsker å forstå hvordan vær og andre faktorer påvirker bruken av bysyklene, blant annet for å planlegge vedlikehold av sykkelparken i perioder med lav etterspørsel.

Datasettet `sykler` inneholder daglige observasjoner fra perioden 2018–2022. Last inn datasettet i R-minnet ved hjelp av følgende kommando, der vi antar at filen ligger i arbeidsmappen din:

```
load("sykler.Rdata")
```

En oversikt over variablene i datasettet finner du i Tabell 1. I tillegg inneholder filen datasettet `neste10`, som inneholder værprognoser og øvrig informasjon for de ti dagene etter eksamensdatoen.

Tabell 1: Beskrivelse av variabler i datasettet `sykler`.

| Variabelnavn           | Beskrivelse                                                                   |
|------------------------|-------------------------------------------------------------------------------|
| <code>date</code>      | Dato for observasjon                                                          |
| <code>nrider</code>    | Antall fullførte sykkelturner med varighet over ett minutt                    |
| <code>precip</code>    | Nedbør i Bergensområdet i løpet av denne dagen (mm)                           |
| <code>temp</code>      | Gjennomsnittlig temperatur i Bergensområdet denne dagen (celsius)             |
| <code>snow</code>      | Snødekke i bebygde område (mm vannekvivalent)                                 |
| <code>isweekend</code> | Dummyvariabel: <code>TRUE</code> = lørdag/søndag, <code>FALSE</code> = ukedag |
| <code>month</code>     | Måned for observasjon (faktor)                                                |
| <code>year</code>      | År for observasjon (faktor)                                                   |

### Oppgave 1 – Deskriptiv statistikk

- (a) Lag et histogram av `nrider`. Lag et spredningsplott av `nrider` mot `temp`, og et spredningsplott av `log(nrider)` mot `temp`. Kommenter hva figurene forteller deg om fordelingen av antall sykkelturner og sammenhengen med temperatur.
- (b) Lag et boksplott som sammenligner `nrider` mellom helgedager og ukedager. Lag et boksplott som sammenligner `nrider` mellom månedene. Kommenter hva figurene forteller deg.

Bergen Bysykkel har en hypotese om at sykkelturner i ukedagene i stor grad er knyttet til pendling (skole og arbeid), der folk sykler mer uavhengig av regn, mens sykkelturner i helgene i større grad er knyttet til fritidsaktiviteter og dermed mer følsomme for dårlig vær.

- (c) Beregn korrelasjonen mellom `nrider` og `precip` for henholdsvis ukedager og helgedager. Kommenter resultatet i lys av hypotesen over.

### Oppgave 2 – Hypotesetesting

- (a) Gjennomfør en t-test for å undersøke om det er en signifikant forskjell i gjennomsnittlig antall sykkelturner mellom helgedager og ukedager. Formuler null- og alternativhypotese, og tolk resultatet.

### Oppgave 3 – Regresjon

I oppgavene under bruker vi `log(nrides)` som responsvariabel i regresjonsmodellene.

- (a) Tilpass en log-lineær regresjonsmodell med `log(nrides)` som responsvariabel og `precip`, `temp`, `snow`, `isweekend` og `month` som forklaringsvariabler. Vis resultatet av modelltilpasningen og gi en fortolkning av koeffisientene for `precip`, `temp` og `isweekend`.
- (b) Lag følgende diagnoseplott for modellen i (a): residualer mot predikerte verdier, QQ-plott og autokorrelasjonsplott av residualene. Hvilke forutsetninger for lineær regresjon kan disse plottene si noe om, og er forutsetningene oppfylt?

Bergen Bysykkel ønsker å utføre vedlikehold på sykkelparken i perioder med lav etterspørsel. Datasettet `neste10` inneholder værprognoser og øvrig informasjon for de neste ti dagene.

- (c) Bruk modellen til å predikere `log(nrides)` for de neste 10 dagene og transformer prediksjonene tilbake slik at de uttrykkes i antall sykkelturer. Basert på prediksjonene, hvilken dag ville du anbefalt Bergen Bysykkel å utføre vedlikehold?

I Oppgave 1c gjorde du en enkel kvantitativ undersøkelse av Bysykkels hypotese om at nedbør har en sterkere effekt på antall turer i helgene enn på ukedager.

- (d) Utvid regresjonsmodellen fra (a) slik at du kan teste denne hypotesen mer formelt. Tolk resultatet.

### Oppgave 4 – Tidsrekker

Variabelen `nrides` er en tidsrekke med daglige observasjoner ordnet etter dato.

- (a) Plott `nrides` som en tidsrekke og lag et autokorrelasjonsplott. Bruk figurene til å vurdere om tidsrekken er stasjonær.

Den siste datoen i datasettet er onsdag 30. november 2022.

- (b) Bruk `auto.arima()` til å tilpasse en tidsrekkemodell for `nrides`. Hvilken modell velger `auto.arima()`? Prediker antall sykkelturer for de 15 påfølgende dagene og lag en figur av prediksjonen. Ser modellen ut til å plukke opp helgeeffekten?

## Del 2 - Regne- og tolkningsoppgaver

Yrkesdeltakelsen blant unge i alderen 20–35 år har falt de siste årene. Fra 2026 innfører norske myndigheter et nytt **arbeidsfradrag** rettet mot denne aldersgruppen. Fradraget reduserer skatten for dem som er i arbeid, og er ment å gjøre det mer lønnsomt å jobbe. Det fases gradvis inn fra en bruttoinntekt på 120 000 kr, gir maksimalt 27 500 kr i skattelettelse ved en inntekt rundt 335 000 kr, og fases helt ut for inntekter over 658 000 kr.

Det er på forhånd usikkert om fradraget faktisk vil føre til at folk jobber mer. Lavere skatt gjør riktignok hver arbeidstime mer lønnsom, noe som kan trekke i retning av mer arbeid (substitusjonseffekten). Men skattelettelsen gjør det også mulig å opprettholde samme inntekt med færre timer, noe som kan trekke i motsatt retning (inntektseffekten). Hvilken av disse effektene som dominerer er et empirisk spørsmål.

For å få et bedre beslutningsgrunnlag innfører myndighetene fradraget som et randomisert forsøk: **100 000 personer trekkes tilfeldig ut** til å motta fradraget. Trekningen skjer blant alle som er berettiget til fradraget, dvs. personer med bruttoinntekt mellom 120 000 og 658 000 kr. De resterende **1 150 000** personene i aldersgruppen utgjør en kontrollgruppe. Vi kaller dem som ble trukket ut for *vinnere* og dem som ikke ble trukket for *ikke-vinnere*.

Alle  $n = 1\,250\,000$  personer er observert i to perioder: ett år *før* og ett år *etter* trekningen. Datasettet er dermed et *paneldatasett* med to observasjoner per person. I noen oppgaver brukes et tilfeldig trukket utvalg på  $n = 500$  fra dette panelet; i andre brukes hele populasjonen. Hver oppgave angir hvilket datasett som benyttes.

Tabell 2 gir en oversikt over variablene.

Tabell 2: Variabelbeskrivelse

| Variabel   | Beskrivelse                                                        |
|------------|--------------------------------------------------------------------|
| id         | Unik person-ID                                                     |
| periode    | <b>Før</b> (ett år før trekning) eller <b>Etter</b> (ett år etter) |
| etter      | 1 hvis periode = <b>Etter</b> , 0 hvis periode = <b>Før</b>        |
| vinner     | 1 hvis trukket til arbeidsfradrag, 0 hvis ikke trukket             |
| ansatt     | 1 hvis i arbeid, 0 hvis ikke i arbeid                              |
| timer      | Arbeidstimer per uke (kun observert for sysselsatte)               |
| alder      | Alder i år                                                         |
| kjonn      | <b>Mann</b> eller <b>Kvinne</b>                                    |
| utdanning  | Antall år høyere utdanning                                         |
| inntekt    | Bruttoinntekt (1 000 kr)*                                          |
| skattesats | Gjennomsnittlig effektiv skattesats (%)**                          |

\* **inntekt** er målt ett år *før* skattelotteriet for alle observasjoner, også de som er observert ett år *etter*.

\*\* **skattesats** er beregnet fra bruttoinntekten ett år *før* skattelotteriet. I paneldatasettet varierer skattesatsen mellom periodene: vinnere får lavere skattesats i etter-perioden som følge av arbeidsfradraget.

*Merk: Dataene i oppgavene er simulerte og representerer ikke resultater fra et faktisk gjennomført forsøk.*

## Oppgave 5 – Regresjon: skattesats og arbeidstimer

Før lotteriekspperimentet analyseres, undersøker forskerteamet sammenhengen mellom skattesats og arbeidstimer. Analysen bruker data fra ett år før skattelotteriet og begrenses til de 1 036 618 sysselsatte i populasjonen. Tabellen nedenfor viser to lineære regresjoner der **timer** er utfallsvariabel (responsvariabel): modell (1) inkluderer kun **skattesats**, mens modell (2) legger til **inntekt** som kontrollvariabel.

Tabell 3: OLS-regresjon: utfallsvariabel timer

|              | (1)                    | (2)                    |
|--------------|------------------------|------------------------|
| Konstantledd | 21.2950***<br>(0.0412) | 31.7179***<br>(6.5312) |
| skattesats   | 0.4700***<br>(0.0013)  | -0.2248<br>(0.4354)    |
| inntekt      |                        | 0.0243<br>(0.0152)     |
| Num.Obs.     | 1 036 618              | 1 036 618              |
| R2           | 0.110                  | 0.110                  |

\*  $p < 0.1$ , \*\*  $p < 0.05$ , \*\*\*  $p < 0.01$

- (a) Tolk koeffisienten for **skattesats** i modell (1). Diskuter mulige mekanismer som kan forklare sammenhengen.
- (b) Sammenlikn koeffisienten og standardfeilen for **skattesats** i modell (1) og (2). Hva kan forklare endringen? *Hint: Korrelasjonen mellom **skattesats** og **inntekt** i disse dataene er tilnærmet perfekt ( $r \approx 1.00$ ).*

## Oppgave 6 – Logistisk regresjon

Vi ser nå på hele populasjonen ( $n = 1\,250\,000$ ) i året etter skattelotteriet. Tabellen nedenfor viser en logistisk regresjonsmodell der responsvariabelen er **ansatt** (1 = i arbeid). Merk at **inntekt** er målt i året *før* skattelotteriet gjennomføres.

Tabell 4: Logistisk regresjon:  $\text{ansatt} \sim \text{vinner} + \text{alder} + \text{utdanning} + \text{inntekt}$

|              | ansatt                |
|--------------|-----------------------|
| Konstantledd | 0.4580***<br>(0.0156) |
| vinner       | 0.1632***<br>(0.0091) |
| alder        | 0.0206***<br>(0.0005) |
| utdanning    | 0.0525***<br>(0.0017) |
| inntekt      | 0.0012***<br>(0.0000) |
| Num.Obs.     | 1 250 000             |

\*  $p < 0.1$ , \*\*  $p < 0.05$ , \*\*\*  $p < 0.01$

- (a) Skriv opp den estimerte modellen. Beregn sannsynligheten for at en person er i arbeid gitt følgende verdier:  $\text{vinner} = 1$ ,  $\text{alder} = 28$ ,  $\text{utdanning} = 3$ ,  $\text{inntekt} = 350$ . Klassifiser personen med en grenseverdi på 0.5.
- (b) Tolk koeffisienten for  $\text{vinner}$ , og diskuter hva som kan forklare resultatet. Kan koeffisienten tolkes kausalt?

## Oppgave 7 – Hypotesetest

Har vinnere og ikke-vinnere ulikt antall arbeidstimer i året etter skattelotteriet? Tabellen nedenfor viser en statistisk test av forskjellen i arbeidstimer mellom vinnere og ikke-vinnere, basert på et tilfeldig trukket utvalg på  $n = 500$ , hvorav 413 er sysselsatte (33 vinnere og 380 ikke-vinnere).

```
##
##  Welch Two Sample t-test
##
## data:  timer by vinner
## t = 1.4396, df = 38.479, p-value = 0.1581
## alternative hypothesis: true difference in means between group 0 and group
##      1 is not equal to 0
## 95 percent confidence interval:
## -1.361456  8.073992
## sample estimates:
## mean in group 0 mean in group 1
##      35.69263      32.33636
##
```

I testen refererer “group 0” til de som har  $\text{vinner}=0$  (ikke vinnere), mens “group 1” referer til de som har  $\text{vinner}=1$  (vinnere).

- (a) Hvilken test er benyttet, og hvorfor er denne testen et rimelig valg her? Sett opp null- og alternativhypotesen. Hva bør ligge til grunn for valget av signifikansnivå i denne sammenhengen, og hva velger du? Konkluder basert på utskriften over.

Forskerne gjennomfører den *samme* testen på alle  $n = 1\,250\,000$  deltakere. Resultatet er vist i tabellen nedenfor.

```
##
##  Welch Two Sample t-test
##
## data:  timer by vinner
## t = 70.984, df = 101327, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group 0 and group
##      1 is not equal to 0
## 95 percent confidence interval:
##  3.253491 3.438263
## sample estimates:
## mean in group 0 mean in group 1
##      35.60550      32.25962
##
```

- (b) Sammenlikn de to testresultatene ovenfor: hva har endret seg, og hvorfor? Er differansen i arbeidstimer *økonomisk* signifikant?

## Oppgave 8 – Paneldata og faste effekter

Vi bruker nå hele populasjonen ( $n = 1\,250\,000$ ) fra begge år. Tabellen nedenfor viser gjennomsnittlig arbeidstimer per uke fordelt på gruppe og periode.

Tabell 5: Gjennomsnittlig arbeidstimer per uke, etter gruppe og periode

| Gruppe       | Før   | Etter |
|--------------|-------|-------|
| Ikke-vinnere | 35.47 | 35.61 |
| Vinnere      | 34.14 | 32.26 |

- (a) Beregn hvor mye arbeidstimene endret seg fra Før til Etter for henholdsvis vinnere og ikke-vinnere. Ta deretter differansen mellom de to endringene, og kommenter kort hva denne størrelsen sier oss.

Tabellen nedenfor viser en panelregresjon med individ-faste effekter der `timer` forklares av `etter` og interaksjonen `vinner × etter`. Interaksjonsleddet er et *difference-in-differences*-estimat (DiD) på effekten av fradraget.

Tabell 6: Panelregresjon med individ-faste effekter: `timer ~ etter + vinner x etter`

|                                              | timer                  |
|----------------------------------------------|------------------------|
| etter                                        | 0.1438***<br>(0.0189)  |
| vinner x etter                               | -2.0471***<br>(0.0668) |
| Num.Obs.                                     | 1 732 466              |
| R2 Within                                    | 0.001                  |
| * $p < 0.1$ , ** $p < 0.05$ , *** $p < 0.01$ |                        |

- (b) Skriv opp modellen og tolk koeffisientene for **etter** og **vinner**  $\times$  **etter**.
- (c) Hva kontrollerer individ-faste effekter for? Forklar hvorfor DiD-estimatet kan gi et mer pålitelig bilde av effekten enn gjennomsnittsforskjellen i Oppgave 7. Bruk tabellen nedenfor til å underbygge svaret.

Tabell 7: Bakgrunnsvariabler ett år før skattelotteriet, for vinnere og ikke-vinnere (populasjonen)

|                            | Vinnere ( $n = 100000$ ) | Ikke-vinnere ( $n = 1150000$ ) | Differanse |
|----------------------------|--------------------------|--------------------------------|------------|
| Alder (år)                 | 27.5                     | 27.5                           | 0          |
| Andel kvinner (%)          | 52                       | 52                             | 0          |
| Utdanning (år høyere utd.) | 2.3                      | 2.3                            | 0          |
| Bruttoinntekt (1 000 kr)   | 342                      | 421                            | -79***     |

Note: \*\*\*  $p < 0.01$ , \*\*  $p < 0.05$ , \*  $p < 0.10$ . Differanse = vinnere – ikke-vinnere; stjerner fra to-utvalgs t-test. Merk at bruttoinntekt er lavere for vinnere enn ikke-vinnere: dette er ikke et tegn på skjevhet i trekningen, men en konsekvens av at lotteriet kun gjaldt for personer med inntekt mellom 120 000 og 658 000 kr. Kontrollgruppen inkluderer også personer utenfor dette intervallet.

## Oppgave 9 – Paneldata og faste effekter: skattesats

I Oppgave 5 så vi at sammenhengen mellom **skattesats** og **timer** i et tverrsnitt er vanskelig å tolke kausalt. Vi estimerer nå en modell med individ- og tidsfaste effekter (TWFE) der **skattesats** er forklaringsvariabel. Merk at **skattesats** er beregnet fra bruttoinntekten i året før eksperimentet, og at vinnere får lavere skattesats i etter-perioden som følge av arbeidsfradraget. Tabellen nedenfor viser resultatet.

Tabell 8: TWFE-regresjon:  $\text{timer} \sim \text{skattesats}$

|            | timer                 |
|------------|-----------------------|
| skattesats | 0.3349***<br>(0.0122) |
| Num.Obs.   | 1 732 466             |
| R2 Within  | 0.001                 |

\*  $p < 0.1$ , \*\*  $p < 0.05$ , \*\*\*  $p < 0.01$

- (a) Diskuter om denne modellen kan gi et mer troverdig estimat av effekten av skattesats på arbeidstimer enn tverrsnittsregresjonen i Oppgave 5. Sammenlikn deretter tilnærmingene i Oppgave 8 og Oppgave 9: hva er den sentrale forskjellen, og når kan den ene være å foretrekke fremfor den andre?